МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РФ

Федеральное государственное автономное образовательное
учреждение высшего образования
ЮЖНЫЙФЕДЕРАЛЬНЫЙУНИВЕРСИТЕТ

Институт математики, механики и компьютерных наук
имени И. И. Воровича

Направление подготовки 02.03.02 – «Фундаментальная информатика
и информационные технологии»

Корчагина М.Д., 3 курс, 1 группа

Курсовая работа

СРАВНЕНИЕ ПОДХОДОВ К РЕФЕРАТИВНОМУ АННОТИРОВАНИЮ ТЕКСТА

Научный руководитель:
доц., к.ф.-м.н. А. В. Абрамян

_____ _____

оценка (рейтинг) подпись руководителя

Ростов-на-Дону
2026

Оглавление

Оглавление 2
Постановка задачи 3
Введение 4
1. Знакомство с задачей 5
1.1 Обзор различных методов суммаризации текста 5
1.2 Обзор способов оценки суммаризации 6
1.2 Обзор базы данных, с которой предстоит работать 7
2. Реализация экстрактивного метода 10
2.1 Сравнение алгоритмов 10
2.2 Выбор алгоритма 12
3. Реализация абстрактивного метода 14
3.1 Выбор модели 14
3.2 Подготовка данных 14
3.3. Настройка параметров обучения 16
3.4 Экспериментальное исследование 19
4. Сравнение результатов 23
4.1 Результаты подходов 23
4.2 Примеры работы обоих методов 23
Заключение 31
Список литературы 33

Постановка задачи

Главная цель данной работы – сравнить экстрактивные и абстрактивные подходы к суммаризации текста на основе количественных метрик и качественного анализа.

Для достижения этой цели необходимо выполнить следующие шаги:

1. Изучить различные методы реферативного аннотирования текста
2. Реализовать экстрактивную суммаризацию текста
3. Реализовать абстрактивную суммаризацию текста
4. Сравнить полученные результаты

Введение

В современном мире человеку каждый день приходится сталкиваться с огромным количеством текстового контента, как в бытовой, так и в рабочей, учебной областях. Усвоение такого объёма информации может потребовать много сил и времени, а потому встаёт вопрос, как сделать этот процесс более простым и эффективным. Ответ пришёл из области машинного обучения. Задача реферативного аннотирования (или суммаризации) – это автоматическое сокращение размера текста без потери его главной смысловой ценности.

В эпоху перенасыщения информацией суммаризация текста является крайне полезным инструментом, который находит применение во множестве разных сфер: в новостных агрегаторах, поисковых системах, системах анализа документов и т.д. [1]

Существует два основных подхода к задаче суммаризации: экстрактивный и абстрактивный. Экстрактивные методы формируют аннотацию из наиболее важных предложений исходного текста, без их изменения. Абстрактивные методы в свою очередь генерируют новый, более короткий, текст на основе исходного.

Несмотря на развитие абстрактивных моделей, экстрактивные методы всё ещё активно используются благодаря своей вычислительной эффективности и интерпретируемости. Абстрактивные же методы обладают большей гибкостью и обобщающей способностью, что делает актуальной задачу сравнительного анализа данных подходов, определение их сильных и слабых сторон.

В данной работе проводится сравнение двух моделей: экстрактивной на основе LSA и абстрактивной предобученной модели T5-small. Оценка проводится с помощью метрик семейства ROUGE и качественного анализа на конкретных примерах из датасета CNN/DailyMail. Платформа Google Colab использовался в качестве среды разработки.

1. Знакомство с задачей

1.1 Обзор различных методов суммаризации текста

Существует два основополагающих подхода к решению задачи референтного аннотирования [1]:

1. Экстрактивный (извлекающий)
2. Абстрактивный (генерирующий)

Суть экстрактивного метода состоит в том, что из исходного текста выбираются предложения, которые наилучшим образом отражают его смысл. Сами предложения при этом остаются неизменными из-за чего полученный текст может казаться недостаточно цельным.

В свою очередь абстрактивный подход способен избегать данной проблемы благодаря генерации нового уникального текста. Результат абстрактивной суммаризации отражает идеи, смыслы и структуру базового текста, но использует для этого перефразирование и синонимы.

На практике реализация экстрактивных алгоритмов является более простой, так как большая их часть основана на применении статистических методов или графов. Это значит, что такие модели не требуется предварительно обучать и можно применять их без предварительной настройки. Немаловажным плюсом является быстрота таких моделей, а также точность, за счёт отсутствия изменённых и добавленных фраз.

Абстрактивные решения основаны на методах машинного и глубокого обучения, что делает их результаты более естественными и приближенными к аннотациям, составленным людьми, но более сложными в реализации. Такие модели требуют наличие обширной обучающей выборки, больше вычислительных ресурсов для использования. Несмотря на это, их применение оправданно при работе с более сложными текстами или группой текстов.

Есть и такие извлекающие методы, которые используют нейросетевые архитектуры, например SummaRuNNer или BertSumExt [1]. Они всё еще

являются более простыми, по сравнению с абстрактивными, но также требуют обучения. Количество примеров для обучения таких моделей обычно значительно меньше, и они показывают удовлетворительные результаты.

Оба этих подхода можно использовать в сочетании. Гибридный подход заключается в экстрактивном сокращении текста и применении к полученному резюме одного из абстрактивный методов. Результатом такого метода является абстрактивная суммаризация, зависящая не от исходного текста, а ограниченная извлечёнными предложениями. Т.е. качество модели может варьироваться в зависимости от эффективности экстрактивного этапа.

1.2 Обзор способов оценки суммаризации

В задачах суммаризации стандартными метриками оценки качества сгенерированного текста являются метрики семейства ROUGE [2]. Их смысл заключается в сравнении полученного текста с эталонным образцом.

На примере рассмотрим, как это работает. Допустим у нас есть сгенерированное моделью предложение и написанный человеком шаблон:

Машинный текст: «Он очень сильно любит пиццу»

Референс: «Он любит пиццу»

Мы можем определить, насколько полно полученное предложение отражает исходное. Для этого подсчитаем количество слов, совпадающих в шаблоне и результате и поделим на общее количество слов в референсе:

$$\text{Recall (полнота)} = \frac{3}{3} = 1$$

Оценка близкая к 1 означает лучший результат. Выходит, что полнота полученного резюме является идеальной, однако визуально легко увидеть, что оно является слишком длинным. Полнота не учитывает данный параметр, а значит для лучшей оценки схожести только её недостаточно. Для этого существует ещё один критерий – точность.

$$Precision\ (\text{точность}) = \frac{\text{количество совпадений в резюме и референсе}}{\text{количество слов в резюме}} = \frac{3}{5} =$$

0,6

Показатель уже не такой хороший, что ближе к правде. Для охвата и полноты и точности используют их гармоническое среднее (F1-мера) :

$$F1 - score = \frac{2 * \text{Precision} * \text{Recall}}{Precision + Recall}$$

Посчитанные в примере Recall, Precision и F1 являются компонентами ROUGE метрики.

Наиболее распространённые их них – ROUGE-N и ROUGE-L.

ROUGE-N отражает пересечение n-грамм, т.е. групп из n слов, в шаблоне и резюме, ROUGE-L – наибольшую общую подпоследовательность слов, делая больший упор на структуру предложения.

Чтобы охватить все аспекты обученной суммаризации модели в данной работе для оценки будут применятся метрики ROUGE-1, ROUGE-2 и ROUGE-L.

1.3 Обзор базы данных, с которой предстоит работать

Поскольку для абстрактивного подхода требуются данные для обучения и тестирования было решено взять стандартный для этой задачи датасет CNN/DailyMail [3]. Он содержит новостные статьи и заголовки к ним на английском языке, написанные журналистами CNN и Daily Mail. Датасет разделён на три набора – тренировочный, валидационный и тестовый.

Рассмотрим его структуру подробнее. Для начала загрузим данные с помощью библиотеки datasets от Hugging Face и выясним сколько записей содержится в каждом из наборов:

```
from datasets import load_dataset
train_data = load_dataset("abisee/cnn_dailymail", "3.0.0", split="train")
```

```
    valid_data = load_dataset("abisee/cnn_dailymail", "3.0.0",
split="validation")
    test_data = load_dataset("abisee/cnn_dailymail", "3.0.0",
split="test")
    print(f"train size = {len(train_data)}")
    print(f"valid size = {len(valid_data)}")
    print(f"test size = {len(test_data)}")
```

Листинг 1

После вывода (см. листинг 1) получили следующие результаты:

train size = 287113

valid size = 13368

test size = 11490

Каждая запись в датасете состоит из следующих столбцов:

'article' – текст статьи

'highlights' – эталонный заголовок к ней

'id' – идентификатор статьи, представляющий хеш её URL-адреса

Также для понимания масштаба задачи узнаем средний размер статей и заголовков. Фрагмент функции, где подсчитывается размер в символах:

```
    def compute_lengths(batch):
        return {
         "article_len_chars": [len(x) for x in batch["article"]],
         "highlights_len_chars": [len(x) for x in
batch["highlights"]]}

    trains_lengths = train_data.map(compute_lengths, batched=True)
    mean_art_s = sum(trains_lengths["article_len_chars"]) /
len(trains_lengths)
    mean_hgl_s = sum(trains_lengths["highlights_len_chars"]) /
len(trains_lengths)
```

Листинг 2

В результате вывода (см. листинг 2) получаем следующие данные:

4033.66 – средний размер статьи в символах

294.77 – средний размер заголовка в символах

691.93 – средний размер статьи в словах

48.72 – средний размер заголовка в словах

Итого заголовки меньше статей примерно на 93%.

2. Реализация экстрактивного метода

2.1 Сравнение алгоритмов

Среди существующих методов экстрактивной суммаризации было принято решение рассмотреть TextRank [4] и LSA [5], так как они относятся к разным классам алгоритмов, не требуют дополнительных ресурсов для обучения как нейросетевые подходы, и являются концептуально более сложными и полными, чем статистические алгоритмы (например, на основе TF-IDF).

TextRank – графовый алгоритм. В его основе лежит алгоритм PageRank, который применяется для ранжирования веб-страниц в поисковых системах. Для начала разберем, как работает PageRank.

Допустим, у нас есть набор веб-страниц, каждая из которых может либо содержать ссылки на другие страницы из этого набора, либо не иметь ссылок вообще. Каждой веб-странице назначается числовое значение – ранг (или вес), зависящий от того, как много других страниц на неё ссылаются. При чём ссылки от страниц с более высоким рангом будут вносить больший вес в ранг страниц. Чем больше ранг, тем выше страница находится в поиске. Определение рангов всех веб-страниц происходит итеративно. Для этого веб-страницы представляются в виде узлов графа, а ссылки между ними образуют рёбра. Алгоритм действует до тех пор, пока веса узлов не стабилизируются.

Для реализации на практике используется матрица смежности, в которой PageRank каждой вершины вычисляется по формуле:

$PR(u) = (1 - d) + d \sum \frac{PR(v)}{L(v)}$, где

d – коэффициент затухания. В случае, если на данную страницу нет ссылок гарантирует, что её PR не будет равен нулю, за счёт возможности спонтанного попадания на неё, а также учитывает, вероятность того, что переход с другой страницы мог не произойти.

PR(v) – ранг страницы, ссылающейся на u,

L(v) - количество уникальных ссылок на этой странице.

TextRank адаптирует PageRank, принимая предложения текста в качестве веб-страниц, а сходство между ними в качестве веса рёбер. В конце алгоритма предложения сортируются в порядке убывания и первые несколько берутся для резюме.

Теперь поговорим об LSA (Latent semantic analysis – латентно-семантический анализ). Чаще он применяется в задачах кластеризации и классификации документа или документов по темам или для уменьшения переобучения, путём сокращения признакового пространства, однако может быть использован и для суммаризации текста. В основе этого метода лежат понятия из линейной алгебры, а именно сингулярное разложение матрицы (Singular Value Decomposition, SVD).

Так как исходная идея алгоритма была разработана для поиска подходящего по смыслу документа в корпусе, для начала разберём его работу в рамках данной задачи. Для этого представим исходный корпус документов в виде матрицы W размера m×n. Строкам матрицы соответствуют слова из общего для всех документов лексикона, а столбцам номера документов. Элементы матрицы отражают встречаемость слов в определённых документах. Это может быть BOW матрица, где для каждого документа используемые в нём слова отмечаются "1", а неиспользуемые "0", или матрица векторов TF-IDF, где для каждого слова отмечена его частотность в документе.

Тогда SVD для отделения тем в корпусе документов имеет вид:

$W_{m\times n} = U_{m\times p} S_{p\times p} V^T_{p\times n}$, где

каждая матрица имеет свой смысл.

U - матрица «слово – тема». В ней p, кол-во тем, равняется m, кол-ву слов. Она отражает корреляцию слов и тем на основе совместной встречаемости слов в документах. Значения в ней отсортированы от верхнего левого угла к правому нижнему по убыванию.

S - диагональная матрица, чьи значения отражают дисперсию в новом измерении тем, т.е. разброс значений для каждой темы. Её элементы отсортированы так же, как и у матрицы «слово – тема». При сжатии векторного пространства, удаляются темы с наименьшей дисперсией, так как отвечают за информацию, которая почти не меняется из документа в документ и не может быть использована для классификации.

V^T - транспонированная матрица «документ –документ». Измеряет частоту использования одинаковых слов в документах, т.е. насколько они семантически похожи.

После разложения темы, несущие наименьшую смысловую нагрузку, усекаются. При усечении тем используется только матрица U - её столбцы удаляются с права налево. Для нахождения подходящего документа поисковой запрос и документы проецируются на пространство тем и для полученных векторов применятся метрики сходства (например, косинусовое сходство).

В применении LSA для суммаризации меняется всего несколько моментов. Во-первых, в исходной матрице по столбцам вместо документов корпуса выделяются предложения текста. Во-вторых, важность конкретных предложений для текста определяется их вкладом в наиболее значимые семантические компоненты с помощью матриц S и V.

2.2 Выбор алгоритма

Для того чтобы оставить один из двух алгоритмов, было решено сравнить их работу на тестовой выборке. Для парсинга статей на предложения, токенизации и последующего суммирования были использованы модули parsers, nlp.tokenizers и summarizers из библиотеки sumy [6]. Для подсчёта метрик библиотека rouge_score. Итого получены следующие значения:

Метод	ROUGE-1	ROUGE-2	ROUGE-L
На основе LSA	0.10378	0.00247	0.06815
TextRank	0.09508	0.00408	0.06687

Таблица 1

По результатам (см. табл. 1) видно, что различия в методах оказались минимальны, однако две из трех метрик всё-таки немного больше у LSA, поэтому оставляем его.

3. Реализация абстрактивного метода

3.1 Выбор модели

Для реализации абстрактивного метода было решено взять одну из предобученных моделей семейства T5 [7] или BART [8], так как это универсальные модели для широкого спектра NLP задач, которые также эффективно показали себя в суммаризации текста. Обе модели основаны на архитектуре encoder-decoder, однако T5 сводит все задачи NLP к “text-to-text”, то есть к преобразованию текста на входе в текст на выходе, а BART обучается посредством восстановления испорченного текста.

Поскольку вычислительные ресурсы рабочего ноутбука были сильно ограниченны, одним из ключевых критериев в выборе модели был её объём. Даже самая маленькая модель семейства BART – BART-base имеет около 130 миллионов параметров, в то время как для моделей T5 их минимальное число будет равняться примерно 60 миллионам. Таким образом благодаря более лёгкой конфигурации и умеренному потреблению памяти окончательный выбор пал на T5-small.

3.2 Подготовка данных

Так как модели Transformer не работают со словами и предложениями на прямую вначале исходные тексты нужно перевести на понятный модели язык. А именно преобразовать его в список целых чисел python (тензоры PyTorch.torch.Tensor, объекты numpy.ndarray), урезать или дополнить до определённого размера. Этот процесс называется предобработкой данных.

Для начала загружаем специальный токенизатор для модели T5 из библиотеки Huggin Face transformers [9]:

```
tokenizer = T5Tokenizer.from_pretrained('google-t5/t5-small')
```

Процесс токенизации оформим в виде функции, принимающей на вход батч данных, то есть группу экземпляров данных определённого

размера. Обработка статей токенизатором внутри производится следующем образом:

```
inputs = self.tokenizer(articles, truncation = True, max_length=256)
```

Здесь параметры truncation = True, max_length = 256 говорят о том, что длинна полученного массива токенов будет урезаться до 256 элементов. Это сделано для того, чтобы сохранить единообразие обрабатываемых данных. Модель может учиться хуже на примерах с большой разницей в длине. Эталонные заголовки кодируются аналогично за исключением максимальной длинны последовательности:

```
labels = self.tokenizer(text_target = highlights, truncation = True, max_length=128)
```

Для них устанавливается меньшая длинна, поскольку уменьшение текста – одна из основных задач модели. Также мы указываем, что данный текст – целевой, после чего объединяем результат токенизации в один батч и возвращаем его:

```
inputs["labels"] = labels["input_ids"]
return inputs
```

В итоге получаем структуру данных, состоящую из токенов статей, заголовков и масок внимания, с которой модель сможет работать дальше.

Ещё одним важным звеном в предобработке данных является Data_collator или загрузчик данных:

```
collator = DataCollatorForSeq2Seq(model = self.model, tokenizer = self.tokenizer, padding = "longest")
```

Его основная задача – это корректное формирование батча, подаваемого на обучении модели. В это входит динамическое дополнение размера последовательностей до самой длинной в наборе. При чём метки будут дополняться значениями -100, что позволит игнорировать их при последующем расчёте значений функции потери.

3.3. Настройка параметров обучения

Для реализации процесса обучения модели использовалось Trainer API из той же библиотеки transformers, которое позволяет абстрагироваться от непосредственной реализации этапов обучения. То есть такие процессы, как:

1. Вычисление потери на этапе обучения;
2. Вычисление градиентов методом обратного распространения ошибки;
3. Обновление весов на основе градиентов;
4. Повторение этих шагов до достижения заданного числа эпох.

Уже встроенные в Trainer API, благодаря чему можно сосредоточиться на тонкой настройке сценария обучения под конкретную задачу. Модуль TrainingArguments с большим количеством разнообразных параметров предоставляет широкие возможности в данной сфере. Рассмотрим подробнее какие настройки понадобились для суммаризации текста (см. листинг 3).

```
training_args = Seq2SeqTrainingArguments(
    output_dir= '/content/drive/MyDrive/trainer_logs',
    save_strategy="epoch",
    save_total_limit=5,
    eval_strategy='epoch',
    metric_for_best_model ='eval_loss',
    load_best_model_at_end=True,
    per_device_train_batch_size=64,
    per_device_eval_batch_size=64,
    predict_with_generate=True,
    generation_max_length=64,
    num_train_epochs=100,
    fp16 = True,
    weight_decay = 0.01,
    learning_rate = 1e-04)
```

Листинг 3

Поскольку в процессе экспериментов выяснилось, что проводить обучение на локальной машине не эффективно из-за ограниченности вычислительных ресурсов, весь процесс проводился в виртуальной среде Google Colab. Ограниченное время сессии не позволяло провести полное обучение за один сеанс, поэтому использовались параметры save_strategy и save_total_limit.

save_strategy отвечает за сохранение состояния модели во время обучения в указанные моменты, в данном случае после каждой эпохи. После сохранения в директории output_dir создаётся опорная точка – checkpoint, с которой при желании можно продолжить обучение. save_total_limit ограничивает количество хранимых checkpoint’ов указанным числом, чтобы не занимать много места на диске.

После каждой эпохи проводилась оценка модели на валидационный наборе данных (eval_strategy='epoch'), а критерием для определения лучшей модели служило уменьшение функции потерь (metric_for_best_model ='eval_loss') (что в последующем было пересмотрено, см. раздел 3.4). Чтобы лучшая модель автоматически сохранялась после обучения использовался load_best_model_at_end=True.

per_device_train_batch_size и per_device_eval_batch_size указывают размер батча данных, используемого на одном шаге обучения и оценки. От количества экземпляров в батче напрямую зависит скорость обучения модели, поэтому предпочтение отдавалось большим значениям. Максимально в память поместился бы батч, размером 128, однако меньшие батчи, хоть и более нестабильны, добавляют в оценку градиента шум, что в ряде случаев увеличивают обобщающую способность. Значение 64 стало идеальной серединой, чтобы избежать переобучения, но сохранить стабильность пересчёта весов.

fp16 = True – разрешение на использование смешанной точности. Повышает эффективность использования вычислительных ресурсов и ускоряет обучение, без существенной потери точности.

Была использована умеренная L2-регуляризацию (weight_decay = 0.01), для предотвращения переобучения, путём штрафования больших весов.

predict_with_generate = True – разрешение генерировать последовательности при оценке модели, что необходимо при использовании таких метрик как ROUGE. generation_max_length=64 ограничивает генерируемый текста 64 токенами.

learning_rate – один из самых важных параметров модели. Он отвечает за скорость обучения. Если выставить скорость слишком большой – модель будет плохо уменьшать ошибку, так как при вычислении градиента может перепрыгивать через минимум функции. Если же поставить скорость слишком маленькой – схождение к минимуму будет очень медленным и потребует огромного количества итераций, более того, появится шанс застрять в локальном минимуме функции. 5e-5 является значением по умолчанию, при размере батча по умолчанию равному 8. Значение 1e-4 было выбрано эмпирически, чтобы поддерживать эффективность обучения для увеличенного батча.

Количество эпох обучения (num_train_epochs = 100) устанавливалось с запасом и на самом деле обучение прекращалось раньше благодаря применению пользовательского метода ранней остановки. После каждой эпохи проверялись значения функции потерь на тренировочном и валидационный датасете и в случае, если потери на последнем росли три эпохи подряд обучение прерывалось. Таким образом процесс заканчивался тогда, когда модель начинала переобучаться. Метод был добавлен в trainer с помощью callback.

3.4 Экспериментальное исследование

Обучение модели, описанной в разделах выше продлилось 36 эпох и было остановлено вручную. Поводом для остановки послужила длительность обучения. В попытках разобраться, что могло пойти не так было выявлено несколько проблем. Во-первых, значение функции потерь уменьшалось, в то время как метрики ROUGE оставались на месте. Во-вторых, на этапе токенизации 256 было максимальным количеством токенов для текста статей, хотя в среднем размер статьи составлял около 950 токенов. То есть значительна часть входной информации отбрасывалась, что могло негативно повлиять на качество модели.

Что бы решить эти проблемы были предприняты следующие шаги:

1. Максимальная длина последовательности токенов для статей увеличилась до 384.

T5-small может обрабатывать последовательности до 512 токенов включительно, однако даже для 384 время одной эпохи значительно увеличилось по сравнению со предыдущим значением, поэтому было решено остановиться на нём.

Поскольку большее количество токенов стало занимать больше памяти, размер батча пришлось уменьшить с 64 до 32.

2. Был изменён критерий остановки.

Как показали результаты запуска прошлой модели – loss не лучшим образом отображает качество суммаризации. Поэтому он был заменён на ROUGE-L, так как эта метрика оценивает соответствие структуры предложения эталонному заголовку целиком, что в данном случае более информативно, чем ROUGE-1 или ROUGE-2.

Также в прошлой версии не было учтено, что остановка обучения должна происходить не тогда, когда loss не улучшался три эпохи подряд, а тогда, когда он не улучшался по сравнению с наилучшим значением, которое уже встречалось. То есть улучшение по сравнению с предыдущей

эпохой, даже если оно было хуже, чем лучшая возможная оценка, обнуляло счётчик ожидания остановки (patience). В этой реализации данная неточность была устранена.

3. Добавлен адаптер LoRA.

Поскольку с увеличением числа обрабатываемых токенов увеличилось время эпохи и вычислительная нагрузка, для её снижения было решено использовать адаптер LoRA с конфигурацией для модели Sequence-to-Sequence (см. листинг 4).

```
config = LoraConfig(task_type= "SEQ_2_SEQ_LM" ,
                            r= 4,
                            lora_alpha= 16,
                            target_modules=[ "q" , "v" ],
                            lora_dropout= 0.01)
```

Листинг 4

Суть Low-Rank Adaptation — адаптация с пониженным рангом заключается в разложении матрицы весов модели на произведение двух меньших матриц с рангом r. Такой подход позволяет сэкономить память за счёт хранения меньшего количества параметров модели и ускорить обучение.

По итогу внесенных изменений были получены следующие результаты:

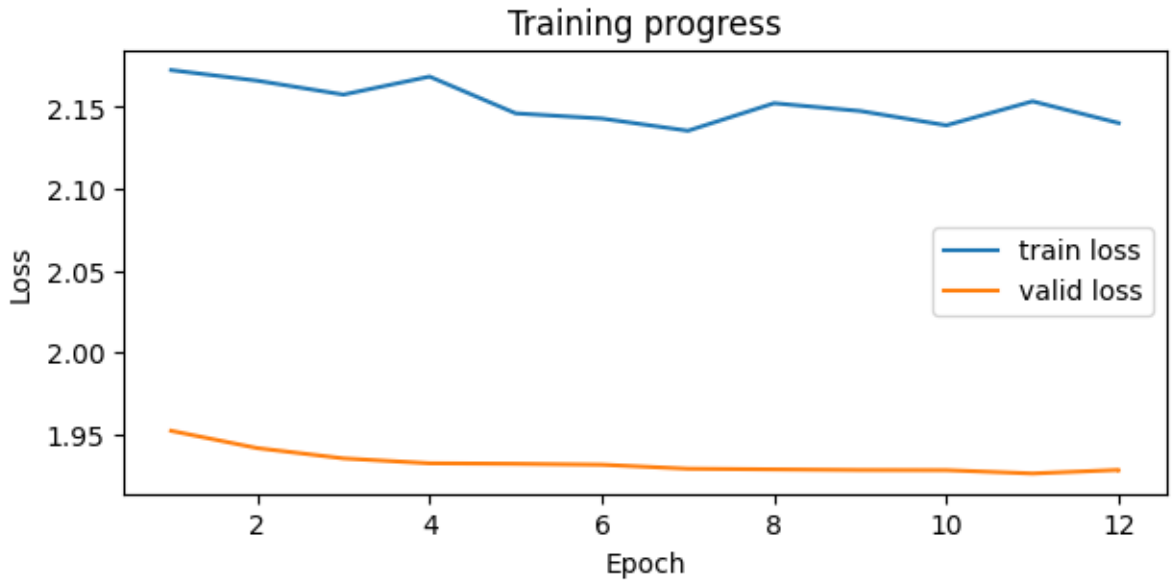


Рисунок 1

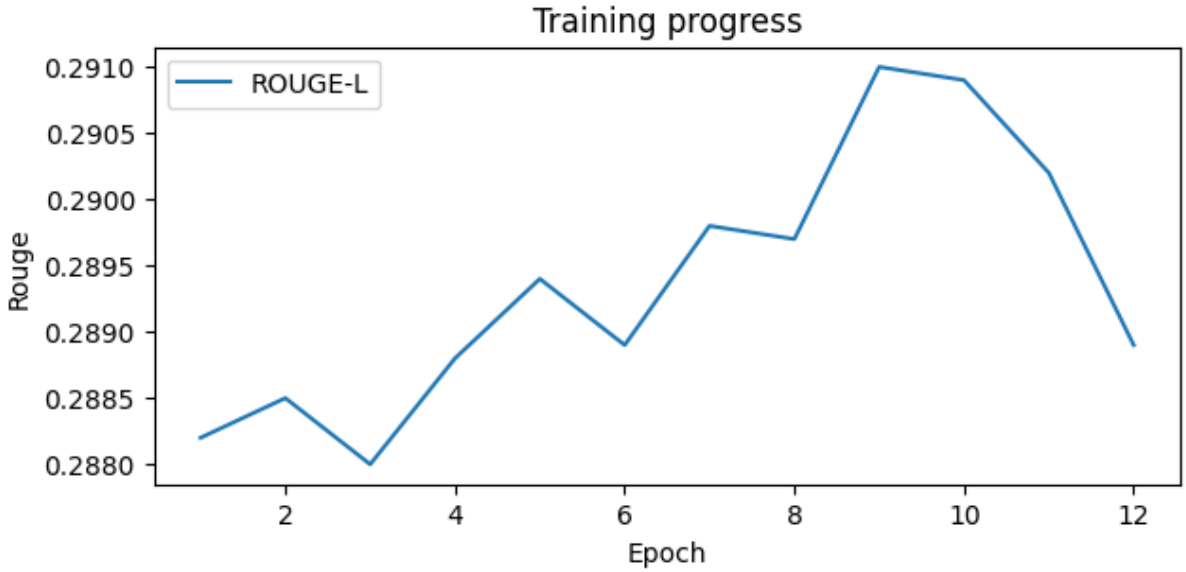


Рисунок 2

По графикам видно (см. рис. 2), что пик метрики ROUGE-L пришёлся на девятую эпоху, в то время как loss (см. рис. 1), как на тренировочном, так и на валидационном наборе ещё некоторое время уменьшался. То есть улучшение метрик прекратилось раньше, чем сошлось loss.

А такая картина наблюдалась на обучении модели до изменений:

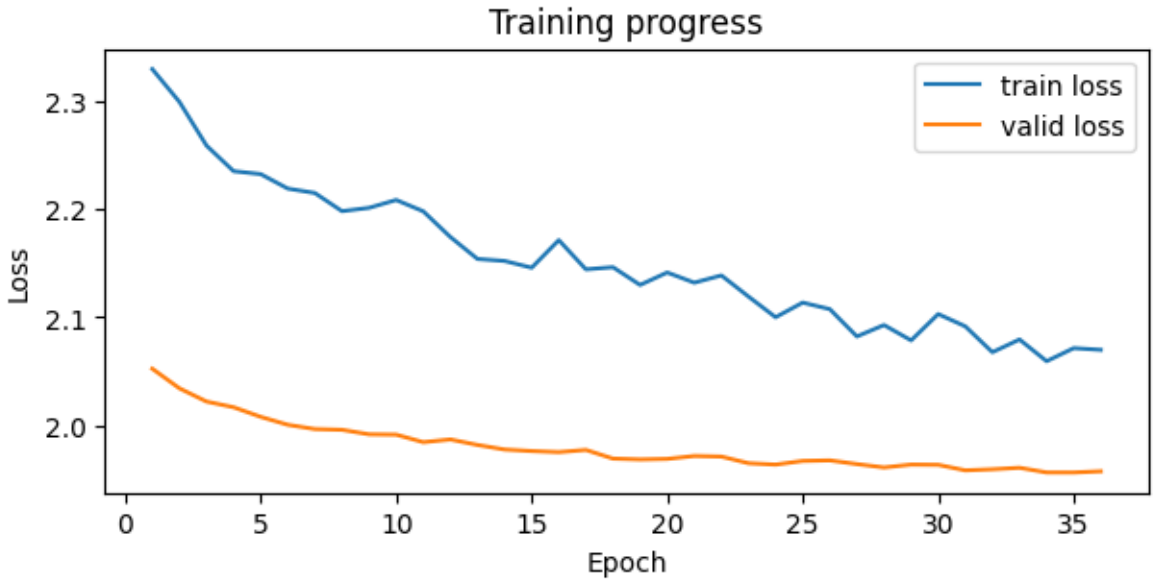


Рисунок 3

Функция потерь (см. рис 3) могла продолжать уменьшатся и дальше, хотя по факту улучшение качества суммаризации остановилось задолго до 36ой эпохи.

Сводная таблица результатов обеих моделей на тестовой выборке:

Модель №	Кол-во эпох	Критерий остановки	ROUGE-1	ROUGE-2	ROUGE-L
1	36	Loss	0.4098	0.1859	0.2892
2	12	ROUGE-L	0.4037	0.1833	0.2862

Таблица 2

Несмотря на то, что метрики второй модели немного ниже (см. табл. 2), модификация процесса обучения позволила сильно сократить затраты по времени, без значительного ухудшения качества суммаризации.

Возможно, выбранное значение счётчика patience в функции ранней остановки могло привести к преждевременному завершению обучения. Его увеличение в теории позволило бы закончить обучение позже и дойти до тех же значений ROUGE, но основной задачей являлась именно снижение вычислительных затрат, и эта цель была достигнута.

В дальнейшем для сравнения методов будем использовать модель, полученную после преобразований.

4. Сравнение результатов

4.1 Результаты подходов

В предыдущих разделах для экстрактивного и абстрактивного методов были получены следующие результаты:

Метод	Модель	ROUGE-1	ROUGE-2	ROUGE-L
Экстрактивный	На основе LSA	0.10378	0.00247	0.06815
Абстрактивный	T5-small	0.4037	0.1833	0.2862

Таблица 3

Наблюдается значительный разрыв в показателях в пользу абстрактивного метода (см. табл. 3). Но если брать во внимание не только метрики, а также время и вычислительные ресурсы, затраченные на подготовку моделей, то для экстрактивного метода они будут практически нулевыми, что может сделать его более привлекательным в ситуациях, когда быстрота и простата в использовании приоритетнее точности суммаризации.

4.2 Примеры работы обоих методов

Теперь проверим как оба метода справляются со своей задачей на разных примерах. Для начала возьмём одну случайную статью из тестового датасета и сравним результаты суммаризаций с эталонным заголовком.

Статья:

Rangers have promised to probe claims Mike Ashley has grabbed control of the club's badges. Reports emerged on social media on Thursday afternoon suggesting the Newcastle United owner was now the official owner of the Light Blues trademarks - including the 'Ready' badge and mascot Broxi Bear. The Sports Direct tycoon had been given security over the icons and logos as part of the £5million loan handed to the previous Gers board in January. Rangers have

promised to probe claims Mike Ashley has grabbed control of the club's badges . Reports emerged suggesting the Newcastle owner was now the official owner of the Light Blues trademarks . But now Dave King's new regime have promised a speedy investigation after documents appeared on the government-run Intellectual Property Office (IPO) website showing the club's trademarks were now controlled by SportsDirect.com Retail Ltd. In a statement a club spokesman said: 'The board is currently conducting a review of all contractual documentation but this particular issue has become a matter of urgency.' News that Ashley has seized hold of more treasured assets will worry the Ibrox faithful. The Londoner is already vastly unpopular after grabbing hold of a 75 per cent share of the club's retail income with his loan deal. Dave King's new regime have promised a speedy investigation into the claims surrounding Ashley . The IPO site confirm the transfer from Rangers Football Club Ltd to Sports Direct was fully assigned on March 25 - less than three weeks after former chief executive and Ashley ally Derek Llambias and finance director Barry Leach, a former Sports Direct executive, were removed at a general meeting called by King. Yet Interim chairman Paul Murray announced two days later that the new board had held 'no discussions with Mike Ashley or Sports Direct'. Rangers announced last week that if they gain promotion to the Premiership, they will have to pay Newcastle £500,000 as part of the deal which saw five Magpies youngsters move to Ibrox on loan. Ashley was given security over the icons and logos as part of the £5m loan handed to the previous board .

В ней содержится 466 токенов. Эталонный заголовок для этой статьи имеет вид:

Reports emerged on social media suggesting Mike Ashley was now the official owner of the Light Blues trademarks .

Rangers have promised to investigate the claims .

Ashley was given security over the icons and logos as part of the £5m loan .

Заголовок, сгенерированный T5-small:

Newcastle United owner Mike Ashley has grabbed control of the club's badges. Reports emerged on Twitter on Thursday afternoon. The Sports Direct tycoon had been given security over the icons and logos. But now Dave King's new regime have promised a speedy investigation.

Заголовок модели на основе LSA:

Rangers have promised to probe claims Mike Ashley has grabbed control of the club's badges. The IPO site confirm the transfer from Rangers Football Club Ltd to Sports Direct was fully assigned on March 25 - less than three weeks after former chief executive and Ashley ally Derek Llambias and finance director Barry Leach, a former Sports Direct executive, were removed at a general meeting called by King. Yet Interim chairman Paul Murray announced two days later that the new board had held 'no discussions with Mike Ashley or Sports Direct'.

Метрики по этой статье:

Метод	Модель	ROUGE-1	ROUGE-2	ROUGE-L	ROUGE-Lsum
Экстрактивный	На основе LSA	0.2443	0.0775	0.1374	0.1832
Абстрактивный	T5-small	0.4706	0.2651	0.2824	0.3765

Таблица 4

Для сравнения результатов на отдельных примерах также была использована метрика ROUGE-Lsum (см. табл. 4), которая, как и ROUGE-L, базируется на вычислении самой длинной общей подпоследовательности

слов. Разница заключается в том, что ROUGE-L вычисляется как среднее по отдельным предложениям, а ROUGE-Lsum рассчитывается целиком по всему тексту. При сравнении подходов на всём тренировочном наборе ROUGE-Lsum не несла новой информации, так как почти не отличалась от обычной метрики, здесь же она отлична и помогает лучше оценить качество суммаризации в целом.

Теперь проверим, как поведут себя модели на самом коротком тексте в наборе. В нём содержится всего 73 токена.

Статья:

The build-up for the blockbuster fight between Floyd Mayweather and Manny Pacquiao in Las Vegas on May 2 steps up a gear on Tuesday night when the American holds an open workout for the media. The session will be streamed live across the world and you can watch it here from 12am UK (7pm EDT).

Эталонный заголовок:

Floyd Mayweather holds an open media workout from 12am UK (7pm EDT) The American takes on Manny Pacquiao in Las Vegas on May 2 . Mayweather's training is being streamed live across the world .

Заголовок от T5-small:

Floyd Mayweather and Manny Pacquiao fight in Las Vegas on May 2. The American holds an open workout for the media on Tuesday night.

Заголовок от модели на основе LSA:

The build-up for the blockbuster fight between Floyd Mayweather and Manny Pacquiao in Las Vegas on May 2 steps up a gear on Tuesday night when the American holds an open workout for the media. The session will be

streamed live across the world and you can watch it here from 12am UK (7pm EDT).

Метрики:

Метод	Модель (алгоритм)	ROUGE-1	ROUGE-2	ROUGE-L	ROUGE-Lsum
Экстрактивный	LSA	0.6444	0.4545	0.3556	0.5778
Абстрактивный	T5-small	0.6552	0.3571	0.3793	0.5172

Таблица 5

Аналогично с предыдущим примером, рассмотрим самый объёмный текст из имеющихся. Он содержит 3688 токенов, поэтому приведём только начало:

(CNN)The nominations for the 69th Annual Tony Awards were announced Tuesday morning. Past Tony winner and three-time nominee Mary-Louise Parker unveiled the nominees with Bruce Willis, who is set to make his Broadway debut in the upcoming play "Misery." The awards are set to be handed out June 7 in a ceremony airing live at 8 p.m. on CBS (tape-delayed on the West Coast) from Radio City Music Hall. Kristin Chenoweth, a nominee for "On the 20th Century," and recent "Cabaret" star Alan Cumming are set to host the ceremony. The full list of nominees is below. Best Play . "The Curious Incident of the Dog in the Night-Time" Author: Simon Stephens . Producers: Stuart Thompson, Tim Levy for NT America, Warner Bros.

Эталонный заголовок:

Actors Kristin Chenoweth and Alan Cumming are set to host the 2015 Tony Awards ceremony . Best play nominees: 'The Curious Incident of the Dog in the Night-Time," "Disgraced," "Hand to God" and "Wolf Hall Parts One & Two"

The awards will be presented on June 7 in a ceremony airing live at 8 p.m. on CBS .

Сгенерировано T5-small:

The nominations for the 69th Annual Tony Awards are announced Tuesday morning. Past Tony winner Mary-Louise Parker unveiled the nominees with Bruce Willis. The awards are set to be handed out June 7 in a ceremony airing live at 8 p.m. on CBS.

Заголовок модели на основе LSA:

Producers: Kevin McCollum, Broadway Global Ventures, CMC, Mastro/Goodman, Jerry & Ronald Frankel, Morris Berchard, Kyodo Tokyo Inc., Wendy Federman, Barbara Freitag, LAMS Productions, Winkler/DeSimone, Timothy Laczynski, Dan Markley, Harris/Karmazin, Jam Theatricals, Robert Greenblatt, Jujamcyn Theaters . "The Visit" Producers: Tom Kirdahy, Edgar Bronfman, Jr., Tom Smedes, Hugh Hayes, Peter Stern, Judith Ann Abrams, Rich Affannato, Hunter Arnold, Carl Daikeler, Ken Davenport, Bharat Mitra & Bhavani Lev, Peter May, Ted Snowdon, Bruno Wang Productions, Taylor Cleghorn, Sandi Moran, Mark Lee & Ed Filipowski, Blodgett Calvin Family, Gabrielle Palitz/Weatherby & Fishman LLC, Marguerite Hoffman/Jeremy Youett, Carlos Arana, Veenerick & Katherine Vos Van Liempt, 42nd.Club/Silva Theatrical, Kate Cannova/Terry Loftis, The Shubert Organization, Williamstown Theatre Festival .

Метрики:

Метод	Модель	ROUGE-1	ROUGE-2	ROUGE-L	ROUGE-Lsum
Экстрактивный	На основе LSA	0.0234	0.0	0.0234	0.0234

Абстрактивный	T5-small	0.5098	0.32	0.3922	0.451

Таблица 6

На основе приведённых примеров можно сделать следующие выводы:

1. Чем больше текст, тем хуже с его суммаризации справляется экстрактивный подход.

Особенно в этом плане показателен последний пример (см. табл. 6). Самая главная информация статьи, о том какое событие, когда, где и кем оно будет проведено, находится в начале статьи. Далее в основном находятся перечисления имён, ролей и наград. T5-small смогла уловить эту закономерность, а модель на основе LSA вообще не содержит ни одного из предложений, которое обычный человек интуитивно посчитал бы важным.

Со статьей с наименьшим количеством токенов, в свою очередь, оба метода справились достаточно хорошо, если судить по метрикам (см. табл. 5). Для экстрактивного подхода они либо незначительно меньше, либо даже лучше, чем у T5-small. Казалось бы, можно делать вывод о том, что в работе с маленькими текстами выгоднее будет использовать экстрактивные методы, но, если внимательнее сравнить исходный текст и суммаризацию, полученную на основе LSA, становится видно, что это одна и та же статья. То есть как такового уменьшения не произошло.

2. Областей применения методов различаются.

Рассмотренные методы суммаризации отличаются не только в метриках, но и в характере получаемого текста. На первой статье хорошо видно, что обе модели смогли передать основную проблематику текста, даже несмотря на то, что формально их оценки относительно эталонного заголовка разнятся.

Экстрактивный подход отбирает предложения из исходного текста без изменений, что обеспечивает высокую точность передачи фактической информации. T5-small в это же время переформулирует содержание и создает более связный и компактный текст.

Таким образом, использовать экстрактивные методы целесообразно в задачах на более коротких текстах, где нужно быстро извлечь ключевую информацию, без изменения формулировок. Абстрактивные же методы предпочтительны, когда важна естественность готового текста и есть достаточно времени и ресурсов на подготовку модели.

Заключение

Целью данной курсовой работы являлось сравнение методов экстрактивной и абстрактивной суммаризации на основе количественных метрик из семейства ROUGE и качественного анализа.

Модель на основе LSA была взята в качестве экстрактивной, для абстрактивной суммаризации использовалась предобученная модель T5-small с последующей тонкой настройкой гиперпараметров и обучением на датасете CNN/DailyMail. По итогам обучения было проведено тестирование моделей, сравнение метрик и результатов суммаризации на конкретных примерах из набора.

В ходе анализа было выявлено, что аннотации абстрактивной модели зачастую являются более качественными, однако в ряде случаев экстрактивные методы также могут давать сопоставимый с абстрактивными результат по количественным метрикам.

Главный вывод работы заключается в том, что метрики не всегда являются достаточным аргументом для выбора того или иного подхода. Стоит также обращать внимание на нюансы работы моделей. Экстрактивные извлекают главные предложения из исходного текста без изменений, в то время как резюме абстрактивных более связны и приближены к естественному построению аннотаций. Также следует учитывать накладные расходы на обучение и вычислительные ресурсы абстрактивных подходов, которые у большинства экстрактивных методов существенно ниже.

Таким образом, основное различие моделей заключается в сферах их применения. Экстрактивные подходят для менее требовательных к качеству суммаризации задач или задач, в которых важно именно сохранение исходных формулировок (например, при обработке юридических текстов). А абстрактивные имеют преимущество в работе с объемными текстами и

задачами, где естественность и связность конечного текста находится на первом месте.

Дальнейшем развитием данной работы может послужить исследование нейросетевых подходов к экстрактивному аннотированию (таких, как SummaRuNNer или BertSumExt) или использование гибридных методов.

Весь исходный код проекта можно посмотреть в репозитории GitHub [10].

Список литературы

1. Allahyari M., Pouriyeh S., Assefi M., et al. Text Summarization Techniques: A Brief Survey // arXiv, 2017.
2. Lin C.-Y. ROUGE: A Package for Automatic Evaluation of Summaries // Proceedings of the ACL Workshop on Text Summarization. 2004.
3. CNN/DailyMail dataset – URL: https://huggingface.co/datasets/abisee/cnn_dailymail
4. Mihalcea R., Tarau P. TextRank: Bringing Order into Text // Proceedings of EMNLP, 2004. – P. 404–411.
5. Хобсон Л., Хапке Х., Коул Х. Обработка естественного языка в действии. СПб.: Питер, 2020. 576 с. (Серия «Для профессионалов»). ISBN 978-5-4461-1371-2.
6. Sumy: Python library for automatic summarization – URL: https://pypi.org/project/sumy/
7. Raffel C., Shazeer N., Roberts A., et al. Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer // JMLR, 2020.
8. Lewis M., Liu Y., Goyal N., et al. BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension // Proceedings of the Annual Meeting of the Association for Computational Linguistics (ACL). 2020.
9. Hugging Face Documentation – URL: https://huggingface.co/docs
10. Исходный код проекта – URL: https://github.com/K-Mariya-D/text-summarization